文字情報ハックのすすめ

An Invitation to Hacking Character Data

Ryusei Yamaguchi / mandel59

BiangBiangCon

データはあるのに

The data is there

調べたい条件で
検索できない

I cannot search by the conditions I care about

その検索を、自分で作ってみる

I can try building that search myself

ハッカーの心構え

A hacker's attitude

自分から問題に取り組む

Take initiative in solving problems

既にある知識や技術を使う

Build on existing knowledge and tools

工夫や成果を共有する

Share the work and what you learn

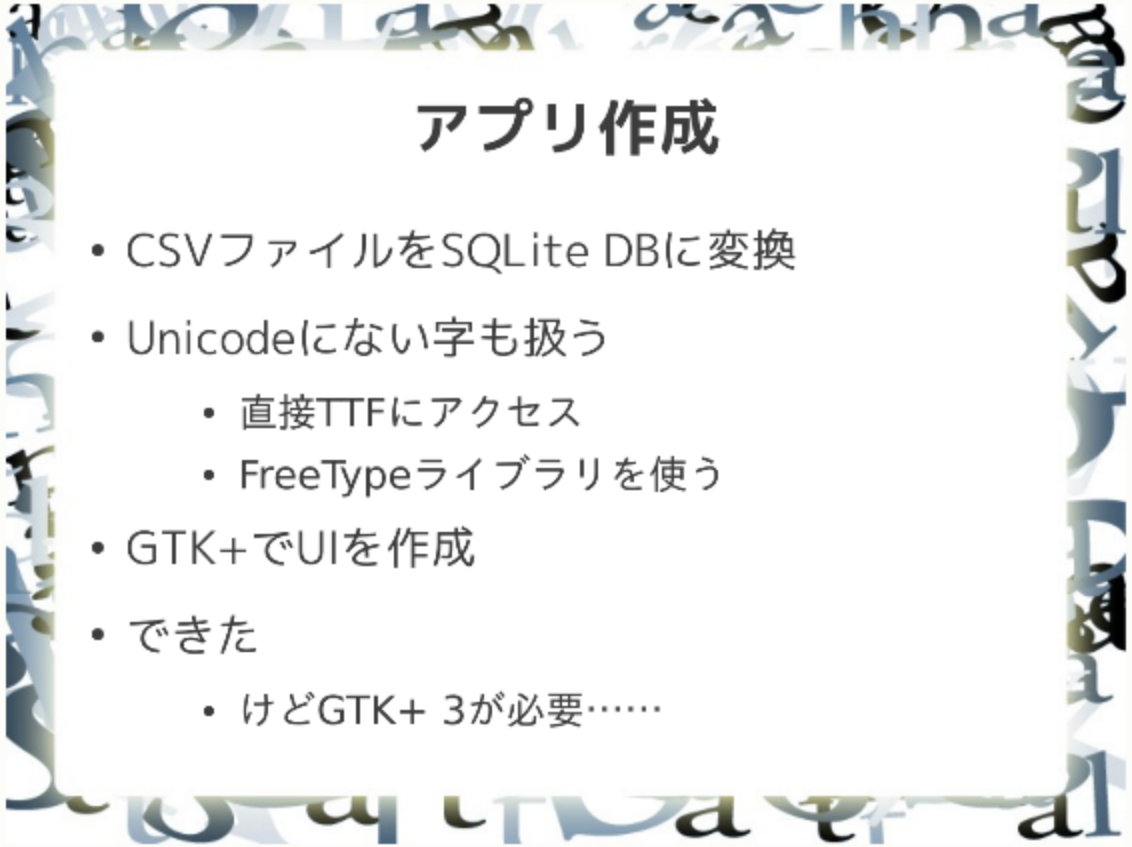
Eric S. Raymond How To Become A Hacker / 日本語訳

2011年のMJ検索

Searching MJ character data in 2011

一覧を取り込んで
自分の検索を作る

Import the list and make it searchable



Ryusei Yamaguchi「IPAmj明朝の漢字を検索」

環境に合わせて道具を選ぶ

Choosing tools for the environment

MJの文字情報一覧

Published MJ character list



CSV + SQLite

Local application

未符号化字はFreeTypeで表示

Render unencoded glyphs from the font

XML + XPath

Web application

未符号化字は画像で表示

Display images of unencoded glyphs

知っている技術で、使える検索にする

Turn available data into a search you can use

検索しやすい形に整える

Preparing data for search

模式例 / Schematic example

字 / Character	値 / Values
弁	瓣 辨 辯

複数値

Multiple values

字 / Character	値 / Value
弁	瓣
弁	辨
弁	辯

個別の行

Separate records

符号位置の表記もそろえる

Use UCS strings as common join keys

字の対応と画数をつなぐ

Connecting relationships and stroke counts

対応元 / Source	対応先 / Target
戹	厄



5画 / 5 strokes

字 / Character	画数 / Strokes
戹	5
厄	4



4画 / 4 strokes

関係の来歴は、出典で確かめる

Check the history in the sources

つくりが魚の漢字

Characters with 魚 on the right

魚へん

Fish on the left

鯖

魚部

Fish radical

つくりが魚

Fish on the right

漁

水部

Water radical

蝓

虫部

Insect radical

構造を条件にする検索

A query for the structure



@ ⿰ ？ 魚

@

字全体

Whole structure

⿰

左右

Left–right

？

左側は任意

Any left component

魚

右側が魚

Fish on the right

mojidata.ryusei.dev

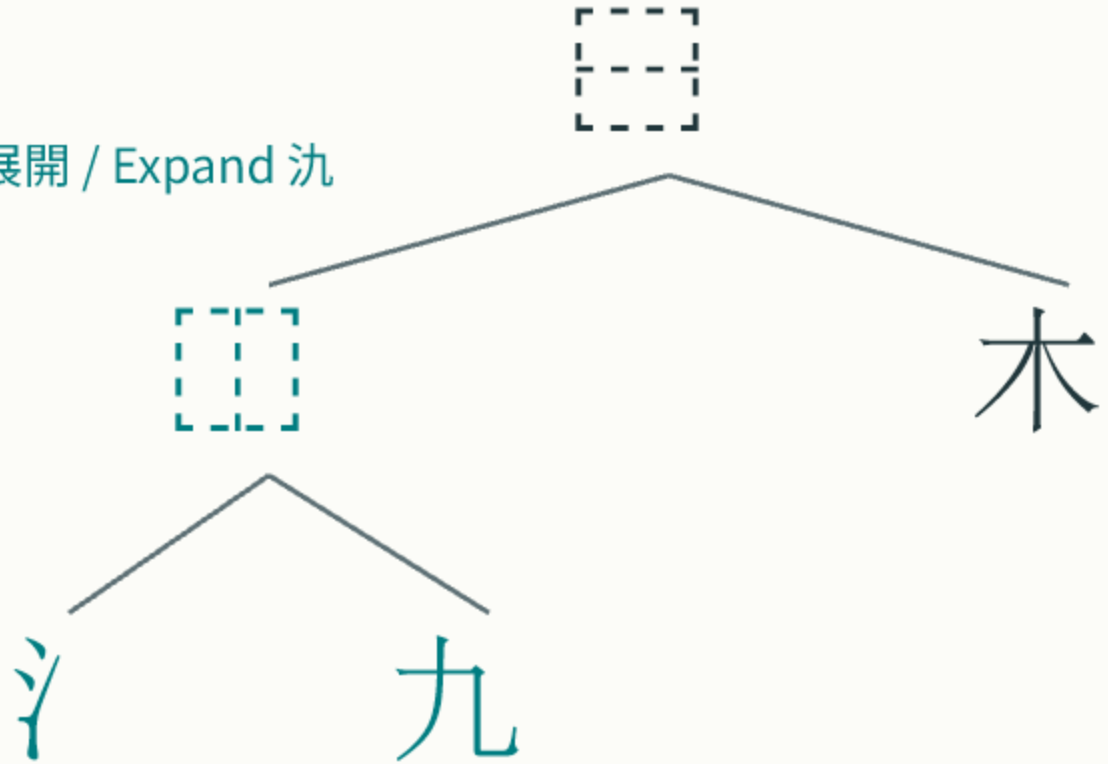
部品を再帰的に辿る

Following components recursively

染

□氿木

氿を展開 / Expand 氿

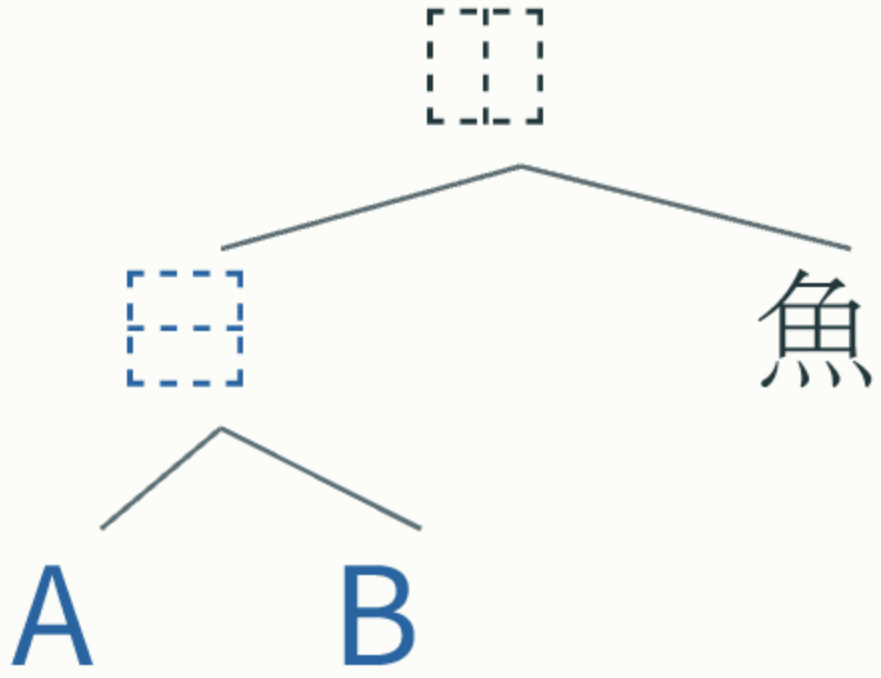


最初の記述にない氵も見つかる

Find 氵 inside a component

木構造を文字列にする

Serializing trees in prefix order





親を先に書く

Write the parent first

部分木は、連続した列になる

A subtree becomes a contiguous sequence

全文検索の技術を応用する

Repurposing full-text search

分解したIDSの列

Serialized decompositions

→

FTSで候補を絞る

Filter with full-text search

→

構造の条件を検査

Verify the structural query

木構造の知識を、汎用の検索技術につなぐ

Bridge character structures and a general-purpose search engine

検索基盤でデータを検査する

Using the search infrastructure to check data

仮説 Hypothesis → **制約** Query constraint → **候補** Candidates → **出典確認** Source review



水部・内画数14

Water radical, 14 residual strokes



総画数 3 → 1

Total strokes: 3 to 1

外れる記録は、調べるべき候補

An inconsistency is a candidate for investigation

似た字の発見とUnihanへの提案

Finding lookalikes and proposing relationships



U+5341



U+2C09B



U+5175



U+2050A

候補を提案

Propose candidates

→

分類を検討

Review classification

→

更新を勧告

Recommend updates

2022 L2/22-133

記憶の知識と、外部化した知識

Knowledge in memory and in shared data

脳の索引

An index in our memory

字の来歴や文脈

History and context

文字の原理への洞察

Insight into character principles

外部化した知識

Externalized knowledge

大量の記録を比較

Compare many records

他の人が検証・再利用

Others can check and reuse it

符号化済みかを調べる知識

Knowledge for checking whether a character is encoded

字形・構造

Glyphs and structures

統合基準

Unification criteria



UCSの抽象文字

Abstract characters in the UCS

UCVなども、再利用できるオープンデータに

Reusable open data for unification criteria such as UCV

使える技能も借りる

Drawing on available skills

最近のMojidata更新は AIにかなり頼っている

I rely heavily on AI for recent Mojidata updates

技能を活用して取り組み、必要なら一緒に学ぶ

Use available skills and learn together when needed

自分で分析し、小さな成果も公開する

Analyze data and share small contributions

気になる問いを試す

Investigate a question you care about

対応表 / Character mappings

誤り候補 / Potential errors

分析クエリ / Analysis queries

出典・利用条件・検証状況を添える

Include sources, reuse terms and verification status

オープンサイエンス

Open science

知識の検証・改善に参加する

Join the review and improvement of knowledge

補足 自由文の区切り文字

Appendix: delimiters in prose

;

値の境界？ 文章中の記号？

A value boundary or punctuation in prose?

kDefinitionの仕様を、実際の文章と照合する

Check the specification against the actual definitions

2024年2月の報告 / Reported in February 2024

補足 最近の更新作業

Appendix: recent maintenance work

日付 / Date	作業 / Work	確認 / Check
2026-09-22	プロパティの差分 Property diffs	定義と実データ Spec and data
2026-09-22	日本の新旧字体 Japanese variants	複数値・検索対象 Values and search
2026-10-10	IVD・文字マップ IVD and cmap	登録差分・既存値 New and existing data

履歴 / Commits: db872f60, 91b03714, 167f36bc

補足 最小画数は条件で変わる

Appendix: the minimum depends on the conditions

対応元 / Source	画数 / Strokes	対応先 / Target	画数 / Strokes
匂	5	丐	4
匂	5	丐	4
宁	5	亠	4
穴	5	冗	4
戾	5	厄	4
疋	5	匹	4

日本の新字体だけなら、收6画と収4画

Japanese shinjitai only: 收 with 6 strokes and 収 with 4

参照文献と入口

References and places to start

ESR How To Become A Hacker（日本語訳）
cruel.org/freeware/hacker.html

Ryusei ハックとデジタル社会
mandel59.hateblo.jp/entry/2023/11/19/212703

MJ文字情報一覧 部首・内画数の誤り
mandel59.hateblo.jp/entry/2024/02/09/005117

Unihanへの類似字提案 / Lookalike proposal
unicode.org/L2/L2022/22133-kspoofing-kzvariant-cand.pdf

UNESCO Open science
unesco.org/en/open-science/about

Mojidata 公開検索 / Search
mojidata.ryusei.dev