BIANGBIANGCON · 2026-10-16

# 文字情報ハックのすすめ

An Invitation to Hacking Character Data

动手玩转文字数据

Ryusei Yamaguchi / mandel59

# 漢字の文字情報を引くMojidataを作っています

I build Mojidata, a web app for looking up kanji character data


## Ryusei Yamaguchi

mandel59

**プログラマー**

Programmer


## Mojidata Web App

`mojidata.ryusei.dev`

漢字を検索し、読み・画数・異体字などの文字情報をまとめて引ける

Type a kanji to look up readings, strokes, variants, IDS and more

**デモを開く**

Open the demo

# 手元のものを組み合わせて作る。これがハック

Built by combining the character data and tools at hand: that is a hack

公開されたデータを

## 集める

Collect character data others have published

手元の技術と

## 組み合わせる

Combine it with the tools at hand

できたものを

## 公開する

Publish what you made

**Mojidataも、こうして作った** Mojidata was made this way

①

# 新字体より画数が多い簡体字は？

Simplified characters with more strokes than shinjitai?




新字体
Shinjitai

簡体字
Simplified

① 新字体より画数が多い簡体字は？ Simplified characters with more strokes than shinjitai?

# 画数の多い簡体字がある。他にもある？

Some simplified forms have more strokes. Are there more?

| 常用漢字<br>Jōyō | 旧字体・繁体字<br>Traditional | 規範字<br>Chinese standard |
|---|---|---|
| 気 6 | 氣 10 | 气 4 |
| 発 9 | 發 12 | 发 5 |
| 広 5 | 廣 15 | 广 3 |
| 電 13 | 電 13 | 电 5 |
| 円 4 | 圓 13 | 圆 10 |

# 材料も道具も、すでに公開されている

The data and the tools are already out there

## データ / Data

**Unihan**
Unihan Database, Unicode Consortium

**IDS**
IDS Database, BabelStone

**MJ文字情報一覧表**
List of MJ Characters, Character Information Technology Promotion Council

**常用漢字表**
Jōyō Kanji Table, Agency for Cultural Affairs

**通用規範漢字表**
List of Common Standard Chinese Characters, State Council of China

## 技術 / Tools

**SQLite** データベース / Database

**全文検索** Full-text search

**JavaScript** プログラミング言語 / Language

→ **Mojidata**
組み合わせたもの
Combined

ステップ1　表を作る Step 1: build the tables

# 日本と中国で、異体字と画数の表を作る

First, build variant and stroke-count tables on each side

## 日本の表 Japan

| 常用漢字・画数 Jōyō, strokes | 異体字 Variants |
|---|---|
| 気 6 | 気 氣 |
| 発 9 | 発 發 |
| 髪 14 | 髪 髮 |
| 電 13 | 電 |

異体字：常用漢字表、Unihan kZVariant、MJ縮退マップ、手で足した6組
画数：MJ文字情報一覧表

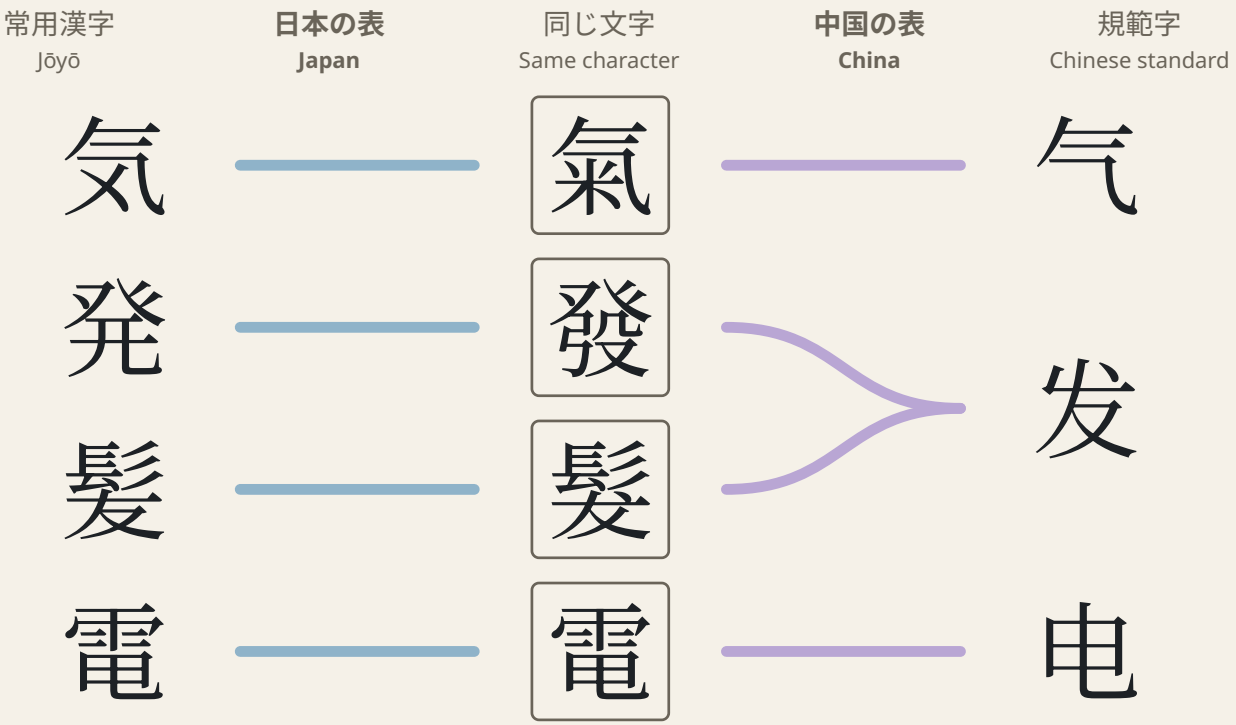
## 中国の表 China

| 異体字 Variants | 規範字・画数 Standard, strokes |
|---|---|
| 气 氣 | 气 4 |
| 发 發 髮 | 发 5 |
| 电 電 | 电 5 |

異体字：通用規範漢字表の異体字表、Unihan kSimplifiedVariant
画数：通用規範漢字表

# 二つの表を、同じ文字でつなぐ

Then join the two tables on the same character

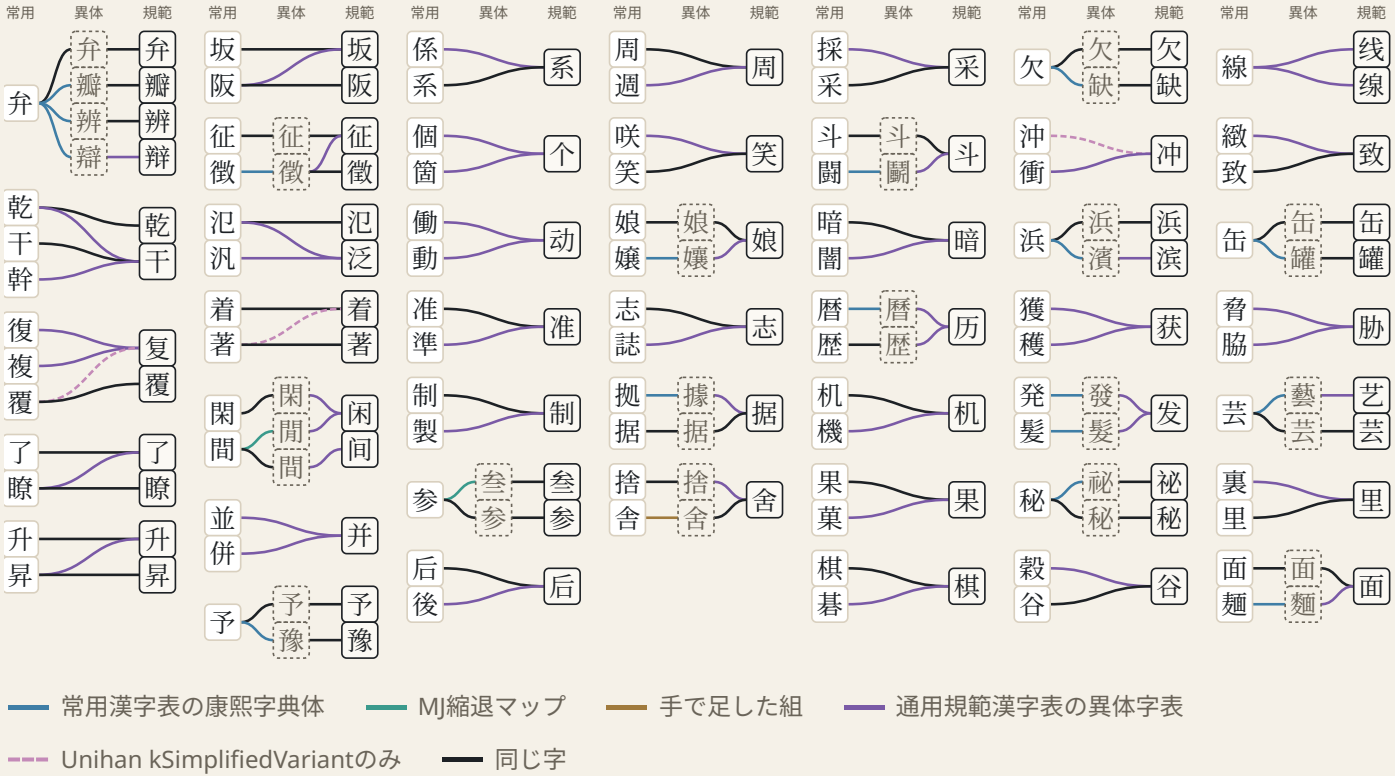


① 新字体より画数が多い簡体字は？ Simplified characters with more strokes than shinjitai?

ステップ2の結果 Step 2 result

# つないだ結果は、表の作り方で変わる

## How you build the tables shapes what the join gives you



ステップ2の結果 Step 2 result

# 常用漢字と規範字の対応表は、2,145組になる

## The table has 2,145 Jōyō–Chinese standard pairs

| | | | | | |
|---|---|---|---|---|---|
| 一 1 → 一 1 | 丁 2 → 丁 2 | 七 2 → 七 2 | 万 3 → 万 3 | 丈 3 → 丈 3 | 三 3 → 三 3 |
| 上 3 → 上 3 | 下 3 → 下 3 | 不 4 → 不 4 | 与 3 → 与 3 | 且 5 → 且 5 | 世 5 → 世 5 |
| 丘 5 → 丘 5 | 丙 5 → 丙 5 | 両 6 → 两 7 | 並 8 → 并 6 | 中 4 → 中 4 | 串 7 → 串 7 |
| 丸 3 → 丸 3 | 丹 4 → 丹 4 | 主 5 → 主 5 | 久 3 → 久 3 | 乏 5 → 乏 4 | 乗 9 → 乘 10 |
| 乙 1 → 乙 1 | 九 2 → 九 2 | 乞 3 → 乞 3 | 乱 7 → 乱 7 | 乳 8 → 乳 8 | 乾 11 → 乾 11 |
| 乾 11 → 干 3 | 亀 11 → 龟 7 | 了 2 → 了 2 | 予 4 → 予 4 | 予 4 → 豫 15 | 争 6 → 争 6 |
| 事 8 → 事 8 | 二 2 → 二 2 | 互 4 → 互 4 | 五 4 → 五 4 | 井 4 → 井 4 | 亜 7 → 亚 6 |
| 亡 3 → 亡 3 | 交 6 → 交 6 | 享 8 → 享 8 | 京 8 → 京 8 | 亭 9 → 亭 9 | 人 2 → 人 2 |
| 仁 4 → 仁 4 | 今 4 → 今 4 | 介 4 → 介 4 | 仏 4 → 佛 7 | 仕 5 → 仕 5 | 他 5 → 他 5 |
| 付 5 → 付 5 | 仙 5 → 仙 5 | 代 5 → 代 5 | 令 5 → 令 5 | 以 5 → 以 4 | 仮 6 → 假 11 |
| 仰 6 → 仰 6 | 仲 6 → 仲 6 | 件 6 → 件 6 | 任 6 → 任 6 | 企 6 → 企 6 | 伎 6 → 伎 6 |
| 伏 6 → 伏 6 | 伐 6 → 伐 6 | 休 6 → 休 6 | 会 6 → 会 6 | 伝 6 → 传 6 | 伯 7 → 伯 7 |

画数：常用漢字はMJ文字情報一覧表、規範字は通用規範漢字表による
Stroke counts: Jōyō from the MJ list, Chinese from the Common Standard list

… 全2,145組 2,145 pairs in all

ステップ3　条件で絞る Step 3: filter

# 対応表を、画数の条件で絞る

Filter the table by stroke count

| | | |
|---|---|---|
| 対応表<br>All pairs | 2,145組 | |
| 常用漢字のほうが多い<br>Jōyō has more | 729組 | 龜11→亀7　価8→价6 |
| 同じ<br>Same | 1,332組 | 一1→一1　乱7→乱7 |
| 規範字のほうが多い<br>Chinese standard has more | 84組 | 円4→圆10　两6→两7 |

① 新字体より画数が多い簡体字は？ Simplified characters with more strokes than shinjitai?

ステップ3の結果 Step 3 result

# 条件で絞ると、84組が残る

## Filtering leaves 84 pairs

| | | | | | |
|---|---|---|---|---|---|
| 両 6 → 两 7 | 乘 9 → 乘 10 | 予 4 → 豫 15 | 仏 4 → 佛 7 | 仮 6 → 假 11 | 侮 8 → 侮 9 |
| 僧 13 → 僧 14 | 円 4 → 圆 10 | 剰 11 → 剩 12 | 効 8 → 效 10 | 勅 9 → 敕 11 | 勤 12 → 勤 13 |
| 収 4 → 收 6 | 咲○ 9 → 笑 10 | 喝 11 → 喝 12 | 器 15 → 器 16 | 図 7 → 图 8 | 圧 5 → 压 6 |
| 増 14 → 增 15 | 墨 14 → 墨 15 | 壌 16 → 壤 20 | 壱 7 → 壹 12 | 売 7 → 卖 8 | 弁 5 → 瓣 19 |
| 弁 5 → 辨 16 | 弁 5 → 辩 16 | 弐 6 → 贰 9 | 弔○ 4 → 吊 6 | 強○ 11 → 强 12 | 彫○ 11 → 雕 16 |
| 徳 14 → 德 15 | 徴 14 → 徵 15 | 恵 10 → 惠 12 | 悔 9 → 悔 10 | 憎 14 → 憎 15 | 戻 7 → 戾 8 |
| 払 5 → 拂 8 | 抜 7 → 拔 8 | 択 7 → 择 8 | 拝 8 → 拜 9 | 拠 8 → 据 11 | 挿 10 → 插 12 |
| 捜 10 → 搜 12 | 掲 11 → 揭 12 | 揺 12 → 摇 13 | 搾○ 13 → 榨 14 | 敏 10 → 敏 11 | 曽 11 → 曾 12 |
| 桜 10 → 樱 15 | 梅 10 → 梅 11 | 欠 4 → 缺 10 | 毎 6 → 每 7 | 毒○ 8 → 毒 9 | 氷○ 5 → 冰 6 |
| 氾○ 5 → 泛 7 | 汎○ 6 → 泛 7 | 沢 7 → 泽 8 | 浜 10 → 滨 13 | 海 9 → 海 10 | 渇 11 → 渴 12 |
| 渓 11 → 溪 13 | 満 12 → 满 13 | 畳 12 → 叠 13 | 痩 12 → 瘦 14 | 砕 9 → 碎 13 | 稲 14 → 稻 15 |
| 穂 15 → 穗 17 | 突 8 → 突 9 | 窓○ 11 → 窗 12 | 粋 10 → 粹 14 | 繁 16 → 繁 17 | 缶 6 → 罐 23 |
| 臭 9 → 臭 10 | 蔵 15 → 藏 17 | 薫 16 → 薰 17 | 衷○ 9 → 衷 10 | 褐 13 → 褐 14 | 覇 19 → 霸 21 |
| 賛 15 → 赞 16 | 酔 11 → 醉 15 | 釈 11 → 释 12 | 髄 19 → 髓 21 | 黒 11 → 黑 12 | 黙 15 → 默 16 |

○ 常用漢字表に康熙字典体なし
No Kangxi form in the Jōyō table

• 規範字表に繁体字なし
No traditional form in the Chinese standard list

# 問いをSQLで書けば、答えが機械的に出る

Write the question in SQL, and the answer comes out mechanically

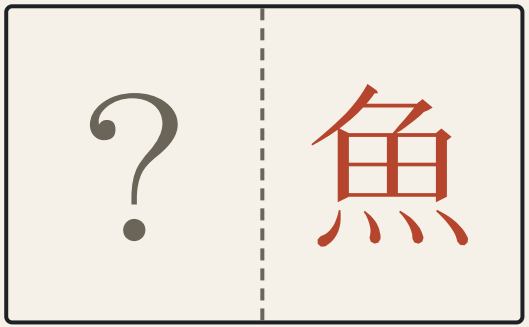
```sql
-- SQLite
WITH
  -- ステップ1：表を作る
  joyo_itaiji (常用漢字, 異体字) AS (
    SELECT 漢字, 康熙字典体 FROM joyo_kangxi
    UNION
    SELECT 漢字, 漢字 FROM joyo
  ),
  japan (常用漢字, 異体字) AS (
    SELECT 常用漢字, 異体字 FROM joyo_itaiji
    UNION
    SELECT joyo_itaiji.常用漢字, unihan_variant.value
      FROM joyo_itaiji
        JOIN unihan_variant
          ON unihan_variant.property = 'kZVariant'
          AND unihan_variant.UCS = joyo_itaiji.異体字
    UNION
    SELECT joyo_itaiji.常用漢字, mji.実装したUCS
      FROM joyo_itaiji
        JOIN mjsm_JIS包摂規準UCS統合規則 AS mjsm
          ON mjsm.縮退UCS = joyo_itaiji.異体字
        JOIN mji ON mji.MJ文字図形名 = mjsm.MJ文字図形名
      WHERE mji.実装したUCS IS NOT NULL
    UNION
    VALUES ('羨', '羡'), ('舎', '舍'), ('舗', '舖'),
      ('諮', '咨'), ('駄', '馱'), ('叱', '叱')
  ),
  china (異体字, 規範字) AS (
    SELECT 异体字, 规范字 FROM tghb_variants
    UNION
    SELECT 规范字, 规范字 FROM tghb
    UNION
    SELECT UCS, value FROM unihan_variant
      WHERE property = 'kSimplifiedVariant'
        AND value IN (SELECT 规范字 FROM tghb)
  ),
  japan_kakusu (常用漢字, 総画数) AS (
    SELECT 実装したUCS, 総画数 FROM mji WHERE 漢字施策
= '常用漢字'
  ),
  china_kakusu (規範字, 笔画) AS (
    SELECT 规范字, 笔画 FROM tghb
  ),
  -- ステップ2：つなぎ合わせる
  jg AS (
    SELECT DISTINCT 常用漢字, 総画数, 規範字, 笔画
      FROM japan
        JOIN china USING (異体字)
        LEFT JOIN japan_kakusu USING (常用漢字)
        LEFT JOIN china_kakusu USING (規範字)
  )
-- ステップ3：絞る
SELECT * FROM jg
WHERE 総画数 < 笔画
ORDER BY 常用漢字, 規範字;
```

- 1 日本の表を作る
- 1 中国の表を作る
- 1 画数の表を作る
- 2 つなぎ合わせる
- 3 絞る

②

# つくりが魚の漢字は？

Characters with 魚 on the right?



② つくりが魚の漢字は？ Characters with 魚 on the right?

# つくりが魚の字は部首がばらばら。全部探すには？

Characters with 魚 on the right sit under many radicals. How to find them all?

### 魚を含む

Contains 魚

鯖 漁

### 魚へん

魚 on the left

鯖

魚部の索引で引ける

In the 魚 radical index

### つくりが魚

魚 on the right

漁 蝕

水部・虫部に散らばる

Scattered across radicals

② つくりが魚の漢字は？ Characters with 魚 on the right?

# ②の解き方：IDSデータを使って検索する

How ②: search with IDS data

検索式 / Query




| 左右に並ぶ Left–right | 左は何でも Anything on the left | 右は魚 魚 on the right |
|---|---|---|

字全体に一致 Matches the whole character

IDSデータ / IDS data

| | | |
|---|---|---|
| 漁 | ⿰氵魚 | ○ |
| 蝓 | ⿰虫魚 | ○ |
| 鯖 | ⿰魚青 | × |

② つくりが魚の漢字は？ Characters with 魚 on the right?

# 実行すると、34字が一度に出てくる

Run it, and 34 characters come out at once

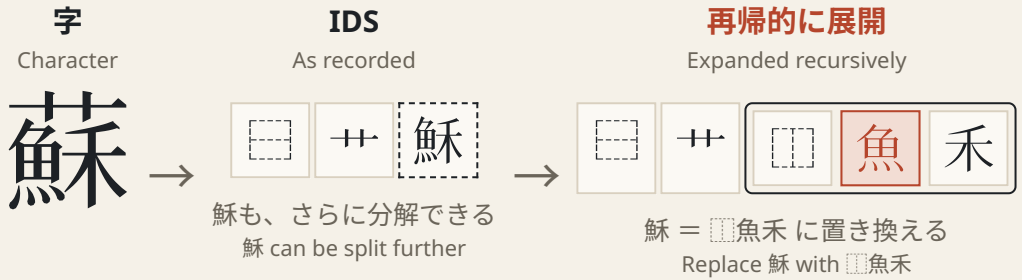
漁 燘 瞗 膃 蝹 鰗 嗚 塩 嫗 強 愉 撫
瞗 燘 醐 鏝 鏀 騭 僥 燘 臼魚 鵆 徧 鱒
穐 鼇 融 嶇 鸇 獲 踰 麴 鬳魚 黦

ids-find --whole=□？魚（字全体に一致）の結果 Result of a whole-character match

② つくりが魚の漢字は？ Characters with 魚 on the right?

# 部品を事前に展開しておくと、中の部品でも引ける

Pre-expanding components makes inner parts searchable




**展開しないで保存**
Stored as is

「魚」では引けない
Not found by 魚

×

**展開して保存**
Stored expanded

「魚」で引ける
Found by 魚

○

② つくりが魚の漢字は？ Characters with 魚 on the right?

# 全文検索で候補を絞り、残りだけ構造を確かめる

Narrow down with full-text search, then check the structure

**IDS検索式**
IDS query



→

**全文検索の検索条件**
Full-text query

"□" AND "魚"

## 1 全文検索で絞る

Keep those containing both □ and 魚

## 2 構造を照合

Check: is 魚 on the right?

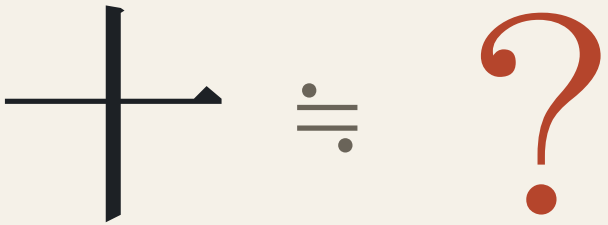
| | | |
|---|---|---|
| 漁 |  | ✓ |
| 鰌 |  | ✓ |
| 鯖 |  | × 魚が左<br>魚 on the left |
| 蘇 |  | × 中の□でも魚が左<br>魚 on the left inside |

仕組みの模式図。全体一致の条件は省略 Schematic; the whole-character condition is omitted

③

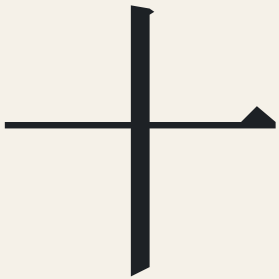
# 常用漢字にそっくりな字はあるか？

Do Jōyō kanji have lookalikes?

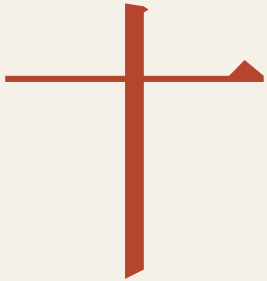


# 常用漢字にそっくりな字がある。他にもある？

Jōyō kanji have lookalikes. Are there more? (2022)



U+5341



U+2C09B

# ③の解き方：常用漢字の全字を、構造で検索する

How ③: search every Jōyō kanji by its structure, all at once (2022)

| 常用漢字<br>Jōyō | | IDS<br>Structure | | 同じIDSを持つ字<br>Characters with the same IDS |
|---|---|---|---|---|
| 十 | → | ⿲一丨 | → | 十 十 |
| 兵 | → | ⿱斤八 | → | 兵 兵 |
| 田 | → | ⿴口十 | → | 田 田 |
| 逸 | → | ⿺辶免 | → | 逸 逸 |

… 常用漢字2,136字のIDSを、ids-findでまとめて検索

All 2,136 Jōyō kanji, searched at once

字ではなくIDSを渡す
Pass the IDS, not the character

常用漢字以外の字が出たら、Unihanの記録と照合
If a non-Jōyō character turns up, check it against Unihan

③ 見つけた字は、Unihanに登録済みか？ Are the lookalikes already in Unihan?

# 照合すると、Unihanにまだない関係があった

Checking Unihan turned up relations not yet recorded (2022)

検索で見つけた組 Found by the search

**10組**

そっくりなのに、関係なし
Lookalikes with no relation

十十 兵兵 了丁 …

**2組**

kZVariantのない字形違い
Variants without kZVariant

緒緒 謠謡

ほかに見つけていた例 Found separately

**1字**

一字だけ未登録
Only one missing

叱叱 ＋ 叱

**L2/22-133**で提案 → **採用（Unicode 15.0）**

Proposed (2022-07) **Adopted for Unicode 15.0**

# あなたの問いから、同じ手順で始められる

Start from your own question, the same way

1

**問いを選ぶ**

Pick a question

2

**材料を探す**

Find data

MJ · Unihan · IDS · Mojidata

3

**道具を選ぶ**

Pick tools

表計算 · SQLite · AI

4

**問いに取り組む**

Work on it

5

**公開する**

Publish

# 字典にない索引を、
# 公開データから作ろう。
# そして、次の人のために公開しよう。

Build the index your dictionary doesn't have — from open data.
Then publish it for the next person.

ありがとうございました / Thank you　—　mandel59

補足 / Backup

③ 2026年に、同じ検索をやり直すと？ What if we rerun the search in 2026?

# 今やると、44字に52の候補が出てくる

Today, the same search gives 52 candidates for 44 Jōyō kanji

| | | | | | |
|---|---|---|---|---|---|
| **了** 了 | **土** 土 | **未** 未本 | **玉** 王 | **緒** 緒 | **逸** 逸 |
| **二** 二二二 | **士** 土 | **本** 未末 | **田** 田 | **臭** 臭 | **隆** 隆 |
| **値** 値 | **央** 央 | **東** 果 | **由** 甲申 | **致** 致 | **類** 類 |
| **兵** 兵 | **巾** 门 | **果** 東 | **甲** 由申 | **蚕** 蚕 | **叱** 叱 |
| **冊** 冂 | **径** 径 | **柿** 柿 | **申** 由甲 | **言** 言 | |
| **十** 十 | **志** 志 | **欄** 欄 | **目** 曰 | **謡** 謡 | |
| **吉** 吉 | **晩** 晩 | **殻** 殻 | **稽** 稽 | **謹** 謹 | |
| **器** 器 | **未** 末本 | **瀬** 瀬 | **突** 突 | **辛** 辛 | |

補足 / Backup

③ 2026年に、同じ検索をやり直すと？ What if we rerun the search in 2026?

# 今やると、まだない候補がまた見つかる

Run it today, and new candidates turn up again

Unihanに収録済みの組 / Pairs already recorded in Unihan

兵兵 了丁 二二二二 目曰 田田 臭臭 叱叱

kSpoofingVariant

逸逸 隆隆 志志 緒緒 謡謡

kZVariant

まだ記録のない候補 / Not yet recorded

**13組**

辛辛

冊冂 央央 玉王 土士 未末本 東果 由甲申 巾门

補足 / Backup

# 十と寸は、同じ読みで似ているのに異体関係がない

十 and 寸 share a reading and a shape, yet are not linked as variants

| | 十<br>U+2C09B | 寸<br>U+2CEB0 |
|---|---|---|
| MJ<br>MJ list | MJ056819 | MJ059293 |
| IDS | ⿻一丨 | ⿻一亅 |
| MJの読み<br>Reading in MJ | えだなし | えだなし |
| 名字の読み<br>As a surname | もぎき | |
| Unihanの異体関係<br>Unihan variants | 十<br>kSpoofingVariant | なし |
| kStrange<br>Unusual forms | 木<br>I: incomplete U+6728 | 才<br>I: incomplete U+624D |

同じ読みで形も似ている。何らかの異体関係として登録されるべきでは

Same reading, similar shape: they should be linked as variants of some kind

「えだなし」の確かな用例をご存じの方は、教えてください

If you know a documented use of the reading “edanashi”, please tell me

補足 / Backup

# ハックとは、取り組み、活かし、公開すること

Hacking means taking on, reusing, and publishing

自発的に

## 取り組む

Take on problems on your own

手元の材料や技術を

## 活かす

Reuse existing work

見つけたことを

## 公開する

Publish what you find

補足 / Backup

# 参照文献 / References


Eric S. Raymond, How To Become A Hacker（日本語訳）
Hacker attitude, skills and sharing

MJ文字情報の問題に関する記事 (2024) ／ Unihanへの報告 (2021)
MJ data issues and Unihan feedback

類似字関係の提案 L2/22-133 (2022) ／ 検討 L2/22-127 §12
Proposed kSpoofingVariant / kZVariant relationships and review

常用漢字と規範字の画数比較 (2022) ／ 日中の読みの集計 (2023)
Stroke and reading comparisons

UNESCO, About Open Science
Access, reuse and participation